Centro Federal de Educação Tecnológica de Minas Gerais - CEFET-MG
Disciplina: Planejamento de Experimentos
Prof.: Fábio Rocha da Silva
Estudo Dirigido II

1 Introdução

Neste estudo dirigido vamos usar os pacotes no R:

- ggplot2
- ggpubr
- tidyverse
- broom
- AICcmodavg

Para instalar estes pacontes use o comando

```
install.packages(c("ggplot2","ggpubr","tidyverse","broom","AICcmodavg"))
```

Carregue os pacotes usando

```
library(ggplot2)
library(ggpubr)
library(tidyverse)
library(broom)
library(AICcmodavg)
```

Agora vamos ler dados gerados para este exemplo.

É comum que os fatores sejam lidos como variáveis quantitativas ao importar um conjunto de dados para o R. Para evitar isso, você pode usar o comando read.csv() para ler os dados, especificando no comando se cada uma das variáveis deve ser quantitativa ("numeric") ou categórico ("factor").

Use o código a seguir, substituindo o texto do "caminho/para/seu/arquivo"pelo caminho real do seu arquivo:

```
crop.data <- read.csv("caminho/para/seu/arquivo/crop.data.csv",
header = TRUE, colClasses = c("factor", "factor", "factor", "numeric"))
```

No caso da minha máquina

```
crop.data <- read.csv("C:/Users/fabio/OneDrive/caminho/para/seu/arquivo/crop.data.csv",
header = TRUE, colClasses = c("factor", "factor", "factor", "numeric"))
```

2 ANOVA

Podemos realizar uma ANOVA em R usando a função aov(). Isso irá calcular a estatística do teste para ANOVA e determinar se há variação significativa entre os grupos formados pelos níveis da variável independente.

2.1 ANOVA a um fator

No exemplo de ANOVA unidirecional, estamos modelando o rendimento da cultura em função do tipo de fertilizante usado. Primeiro, usaremos aov() para executar o modelo, depois usaremos summary() para imprimir o resumo do modelo.

```
one.way <- aov(yield ~ fertilizer, data = crop.data)
summary(one.way)
```

O resumo do modelo lista as variáveis independentes que estão sendo testadas no modelo (neste caso, temos apenas uma, 'fertilizer') e os resíduos do modelo ('Residual').

O restante dos valores na tabela de saída descrevem a variável independente e os resíduos:

- A coluna Df exibe os graus de liberdade para a variável independente (o número de níveis na variável menos 1) e os graus de liberdade para os resíduos (o número total de observações menos um e menos o número de níveis nas variáveis independentes).
- A coluna Sum Sq exibe a soma dos quadrados (ou seja, a variação total entre as médias do grupo e a média geral).
- A coluna Mean Sq é a média da soma dos quadrados, calculada dividindo a soma dos quadrados pelos graus de liberdade de cada parâmetro.
- A coluna F-value é a estatística de teste do teste F. Este é o quadrado médio de cada variável independente dividido pelo quadrado médio dos resíduos. Quanto maior o valor de F, mais provável é que a variação causada pela variável independente seja real e não por acaso.
- A coluna Pr(>F) é o valor p da estatística F. Isso mostra quão provável é que o valor F calculado a partir do teste teria ocorrido se a hipótese nula de nenhuma diferença entre as médias dos grupos fosse verdadeira.

O valor de p da variável fertilizante é baixo ($p < 0{,}001$), portanto, parece que o tipo de fertilizante utilizado tem um impacto real na produtividade final da cultura.

2.2 ANOVA a dois fatores

No exemplo de ANOVA de dois fatores, estamos modelando o rendimento da cultura em função do tipo de fertilizante e da densidade de plantio. Primeiro usamos aov() para executar o modelo, depois usamos summary() para imprimir o resumo do modelo.

```
two.way <- aov(yield ~ fertilizer + density, data = crop.data)
summary(two.way)
```

2.2.1 Adicionando interações entre variáveis

Às vezes você tem motivos para pensar que duas de suas variáveis independentes têm um efeito de interação em vez de um efeito aditivo.

Por exemplo, em nosso experimento de colheita, é possível que a densidade de plantio afete a capacidade das plantas de absorver fertilizantes. Isso pode influenciar o efeito do tipo de fertilizante de uma forma que não é contabilizada no modelo de duas vias.

Para testar se duas variáveis têm um efeito de interação na ANOVA, basta usar um asterisco em vez de um sinal de mais no modelo:

```
interaction <- aov(yield ~ fertilizer*density, data = crop.data)
summary(interaction)
```

Na tabela de saída, a variável 'fertilizer:density' tem um valor de soma de quadrados baixo e um valor p alto, o que significa que não há muita variação que possa ser explicada pela interação entre adubo e densidade de plantio.

2.3 Adicionando um Bloco

Se você agrupou seus tratamentos experimentais de alguma forma, ou se você tem uma variável de confusão que pode afetar o relacionamento que você está interessado em testar, você deve incluir esse elemento no modelo como uma variável de bloco (blocagem). A maneira mais simples de fazer isso é apenas adicionar a variável ao modelo com um '+'.

Por exemplo, em muitos estudos de rendimento de culturas, os tratamentos são aplicados dentro de 'blocos' no campo que podem diferir na textura do solo, umidade, luz solar, etc. Para controlar o efeito das diferenças entre os blocos de plantio adicionamos um terceiro termo, 'bloco ', para nossa ANOVA.

```
blocking <- aov(yield ~ fertilizer + density + block, data = crop.data)
summary(blocking)
```

A variável 'block' tem um valor baixo de soma de quadrados (0,486) e um valor p alto (p = 0,48), então provavelmente não está adicionando muita informação ao modelo. Também não altera a soma dos quadrados para as duas variáveis independentes, o que significa que não afeta quanta variação na variável dependente elas explicam.

2.4 Encontre o modelo mais adequado

Existem agora quatro modelos ANOVA diferentes para explicar os dados. Como você decide qual usar? Normalmente você vai querer usar o modelo de 'melhor ajuste' – o modelo que melhor explica a variação na variável dependente.

O critério de informação de Akaike (AIC) é um bom teste para ajuste do modelo. O AIC calcula o valor da informação de cada modelo equilibrando a variação explicada com o número de parâmetros usados.

Na seleção do modelo AIC, comparamos o valor da informação de cada modelo e escolhemos aquele com o menor valor AIC (um número menor significa mais informações explicadas!)

```
library(AICcmodavg)
model.set <- list(one.way, two.way, interaction, blocking)
model.names <- c("one.way", "two.way", "interaction", "blocking")
aictab(model.set, modnames = model.names)
```

O modelo com a pontuação AIC mais baixa é o melhor ajuste para os dados.

2.4.1 Seleção do modelo AIC

A partir desses resultados, parece que o modelo two.way é o mais adequado. O modelo two-way possui o menor valor de AIC e 71% do peso do AIC, o que significa que explica 71% da variação total da variável dependente que pode ser explicada pelo conjunto completo de modelos.

O modelo com termo de bloqueio contém um adicional de 15% do peso do AIC, mas como é mais de 2 delta-AIC pior que o melhor modelo, provavelmente não é bom o suficiente para incluir em seus resultados.

1. Gere a sua propria tabela crop.data e refaça os passos acima.

3 Estatística Não Paramétrica

Inicialmente vamos gerar uma população com distribuíção assímetrica:

```
x=rgamma(1000000,2,0.5)
hist(x)
plot(density(x))
```

Vamos realizar uma amostragem de tamanho 30 desta população assimétrica:

```
y=sample(x,30)
hist(y)
plot(density(y))
abline(v=mean(x),pch=3,col="red")
```

Vamos verificar se y segue a a distribuição normal:

$$\begin{cases} H_0 & \text{A amostra foi gerada de uma distribuição normalmente distribuída} \\ H_a & \text{A amostra não foi gerada de uma distribuição normalmente distribuída} \end{cases}$$

Para responder a estas Hipóteses usaremos $\alpha = 0.05$ e o teste de Shapiro-Wilk:

```
shapiro.test(y)
```

Sabe-se que a média populacional de nossa váriavel x é igual a

```
mean(x)
```

Vamos ver se o TCL vale para amostras de uma distribuição assimetrica(apenas visualmente)

```
n=30
y=NULL
for(i in 1:10000){
     y[i]=mean(sample(x,n))
}
hist(y)
abline(v=mean(x),pch=3,col="red")
plot(density(y))
abline(v=mean(x),pch=3,col="red")
mean(y)
```

Seja a=mean(x). Vamos fazer o seguinte teste paramétrico

$$\text{Teste Paramétrico} \begin{cases} H_0 & \mu = a \\ H_a & \mu \neq a \end{cases}$$

Vamos verificar se o teste faz a conclusão certa (não rejeitar H_0 com 5% de significância).
Se o teste funcionar para esta distribuição ele rejeitará H_0 (já que ela é correta) em apenas 5% das vezes. Para isto vamos repetir o teste para "infinitas"amostras de tamanho 30 e, para cada amostra, vamos testar o teste acima e verificar se o p-valor é maior que o nível de significância. No final iremos contar quantas vezes a hipótese nula não foi rejeitada. A quantidade $1 - p/10000$ é a proporção de vezes que a hipótese nula foi rejeitada. (Se o tcl funciona é esperado que este número seja aproximadamente igual a α).

```
p=0
n=30
y=NULL
for(i in 1:10000){
     y[i]=(sample(x,n))
     p=ifelse(t.test(y,mu=a)$p.value>0.05,1,0)+p
}

1-p/10000
```

1. Quais as conclusões deste exerício ?
2. diminua o tamanho das amostras e veja o que acontece (n<30)
3. Repita o procedimento de teste mas agora gere duas amostras assimétricas e faça um teste t pareado.