Estudo Dirigido Completo: Simulação Estatística, TCL e ANOVA

Fábio Rocha da Silva / Estatística Computacional e Planejamento Experimental

10 de novembro de 2025

Resumo

Este documento integra conceitos fundamentais de Inferência Estatística e Planejamento Experimental. A primeira parte explora a simulação do Teorema Central do Limite (TCL) em distribuições assimétricas. A segunda parte foca na Análise de Variância (ANOVA) em delineamentos Simples, em Blocos e Fatorial, com ênfase na simulação e interpretação dos testes Post-Hoc (Tukey HSD).

1 Parte I: Simulação do TCL, IC e Distribuições Assimétricas

1.1 Exercício: TCL em População Assimétrica (Exponencial)

O objetivo é simular o TCL para uma população com **Distribuição Exponencial** ($\lambda = 0.2$, $\mu = 5$) e verificar a taxa de cobertura do Intervalo de Confiança (IC) para n grande.

- **População Gerada:** Distribuição Exponencial, $\mu = 5$.
- **Tamanhos Amostrais:** $n = 5$ (pequena) e $n = 50$ (grande).
- **Número de Simulações:** $k = 10.000$.

1.1.1 Código em R: Simulação TCL e Cobertura do IC

Listing 1: TCL e IC para Distribuição Exponencial em R

```r
# Instale o pacote 'moments' se necessario (install.packages("moments"))
# library(moments)

set.seed(1)
pop_assim = rexp(100000, rate = 0.2)
mu_verdadeiro = 5
num_simulacoes = 10000

# 1. Simular o TCL
medias_n50 = NULL
for(i in 1:num_simulacoes){
  amostra_n50 = sample(pop_assim, 50)
  medias_n50[i] = mean(amostra_n50)
}
# print(paste("Assimetria da Dist. Medias (n=50):", moments::skewness(medias_n50)))
# hist(medias_n50) # Espera-se forma Normal

# 2. Simular Cobertura do IC (n=50)
cobertura_ic = 0
for(i in 1:num_simulacoes){
  amostra = sample(pop_assim, 50)
  # Calcula o IC de 95% usando t.test
  intervalo = t.test(amostra, conf.level = 0.95)$conf.int

  if(intervalo[1] < mu_verdadeiro && intervalo[2] > mu_verdadeiro) {
    cobertura_ic = cobertura_ic + 1
```

```
  }
}

proporcao_sucesso = cobertura_ic / num_simulacoes
print(paste("Taxa de Cobertura do IC (Esperada 0.95):", proporcao_sucesso))
```

1.1.2 Código em Python: Simulação TCL e Cobertura do IC

Listing 2: TCL e IC para Distribuição Exponencial em Python

```
import numpy as np
from scipy.stats import t, skew

TRUE_MEAN = 5
RATE = 0.2
POP_SIZE = 100000
NUM_SIMULATIONS = 10000
SAMPLE_SIZE = 50
CONFIDENCE_LEVEL = 0.95

np.random.seed(1)
population = np.random.exponential(scale=1/RATE, size=POP_SIZE)
ic_contains_mean = 0

# 1. Simular TCL (Assimetria)
# print(f"Assimetria da Populacao: {skew(population):.4f}")
# meios_n50 = [np.mean(np.random.choice(population, SAMPLE_SIZE)) for _ in range(
    NUM_SIMULATIONS)]
# print(f"Assimetria Dist. Medias (n=50): {skew(meios_n50):.4f}")

# 2. Simular Cobertura do IC
for _ in range(NUM_SIMULATIONS):
    sample = np.random.choice(population, SAMPLE_SIZE, replace=False)

    sample_mean = np.mean(sample)
    sample_std = np.std(sample, ddof=1)
    standard_error = sample_std / np.sqrt(SAMPLE_SIZE)
    degrees_freedom = SAMPLE_SIZE - 1

    ic_lower, ic_upper = t.interval(
        confidence=CONFIDENCE_LEVEL,
        df=degrees_freedom,
        loc=sample_mean,
        scale=standard_error
    )

    if (ic_lower <= TRUE_MEAN) and (TRUE_MEAN <= ic_upper):
        ic_contains_mean += 1

proportion_success = ic_contains_mean / NUM_SIMULATIONS
print(f"Taxa de Cobertura do IC (Esperada 0.95): {proportion_success:.4f}")
```

—

2 Parte II: Exercícios de ANOVA e Planejamento Experimental

2.1 Exercício 1: ANOVA de Fator Único (One-Way) com Tukey HSD

Cenário: Comparação do tempo de secagem de 3 revestimentos (`A`, `B`, `C`) com $n = 10$ repetições. $\mu_A \approx \mu_B \neq \mu_C$.

Listing 3: ANOVA One-Way com Tukey HSD em R

```
set.seed(123)
```

```r
n_rep <- 10
# Definindo as medias: A=20, B=21 (similares), C=28 (diferente)
Revestimento <- factor(rep(c("A", "B", "C"), each = n_rep))
Media_A <- 20 + rnorm(n_rep, 0, 1.5)
Media_B <- 21 + rnorm(n_rep, 0, 1.5)
Media_C <- 28 + rnorm(n_rep, 0, 1.5)
Tempo_Secagem <- c(Media_A, Media_B, Media_C)

dados_one_way <- data.frame(Revestimento, Tempo_Secagem)

# Ajuste do Modelo ANOVA
modelo_one_way <- aov(Tempo_Secagem ~ Revestimento, data = dados_one_way)
summary(modelo_one_way)

# Teste Post-Hoc de Tukey HSD
tukey_one_way <- TukeyHSD(modelo_one_way, conf.level = 0.95)
print(tukey_one_way)
```

2.2 Exercício 2: Delineamento em Blocos Casualizados (RCBD)

Cenário: Teste de 4 dietas (`D1-D4`) em 3 gaiolas (`G1-G3`) como blocos. Forte efeito de bloco (Gaiola) e efeito de tratamento (D4 superior).

Listing 4: RCBD em R: Efeito de Blocagem

```r
set.seed(456)
Tratamento <- factor(rep(c("D1", "D2", "D3", "D4"), times = 3)) # 4 dietas x 3 blocos
Bloco <- factor(rep(c("G1", "G2", "G3"), each = 4)) # 3 gaiolas (blocos)

# Efeitos: Bloco (G1=0, G2=5, G3=10); Tratamento (D1,D2,D3=0, D4=8)
efeito_bloco_val <- c(0, 5, 10)
efeito_tratamento_val <- c(0, 0, 0, 8)

Ganho_Peso <- numeric(length(Tratamento))
for (i in 1:3) { # Loop pelas gaiolas
  for (j in 1:4) { # Loop pelas dietas
    idx <- (i - 1) * 4 + j
    Ganho_Peso[idx] <- 50 + efeito_bloco_val[i] + efeito_tratamento_val[j] + rnorm(1,
        0, 1)
  }
}

dados_rcbd <- data.frame(Ganho_Peso, Tratamento, Bloco)

# Modelo RCBD e CRD para comparacao
modelo_rcbd <- aov(Ganho_Peso ~ Tratamento + Bloco, data = dados_rcbd)
print("ANOVA RCBD:")
summary(modelo_rcbd)
print("ANOVA CRD (Ignorando Blocos):")
summary(aov(Ganho_Peso ~ Tratamento, data = dados_rcbd))
```

2.3 Exercício 3: ANOVA Fatorial Completa com Interação Forte

Cenário: Produtividade em função de 2 níveis de `Temperatura` (`T1`, `T2`) e 2 níveis de `Irrigacao` (`I1`, `I2`), com $n = 5$ repetições. Interação forte: $\mu_{\text{T1,I2}} \gg \mu_{\text{T2,I2}}$ (inversão do efeito).

Listing 5: ANOVA Fatorial com Interacao e Tukey HSD em Python

```python
import pandas as pd
import numpy as np
from statsmodels.formula.api import ols
from statsmodels.stats.anova import anova_lm
from statsmodels.stats.multicomp import pairwise_tukeyhsd

```

```python
np.random.seed(789)
n_rep = 5

Temperatura = np.repeat(['T1', 'T2'], n_rep * 2)
Irrigacao = np.tile(np.repeat(['I1', 'I2'], n_rep), 2)

# Medias: T1 I1: 100, T1 I2: 120 ; T2 I1: 110, T2 I2: 95
mu_vector_int = np.array(
    [100] * n_rep + [120] * n_rep +
    [110] * n_rep + [95] * n_rep
)

Produtividade = mu_vector_int + np.random.normal(0, 3, size=len(mu_vector_int))
dados_fatorial = pd.DataFrame({'Y': Produtividade, 'Temperatura': Temperatura, 'Irrigacao': Irrigacao})

# Ajuste do Modelo Fatorial (Modelo Tipo II)
modelo_fatorial = ols('Y ~ C(Temperatura) * C(Irrigacao)', data=dados_fatorial).fit()
anova_table_fatorial = anova_lm(modelo_fatorial, typ=2)
print("Tabela ANOVA Fatorial:")
print(anova_table_fatorial)

# Preparacao para Tukey HSD (Combinacao dos Grupos)
dados_fatorial['Grupo'] = dados_fatorial['Temperatura'].astype(str) + ' x ' + dados_fatorial['Irrigacao'].astype(str)

# Aplicacao do Tukey HSD nas 4 combinacoes
tukey_fatorial = pairwise_tukeyhsd(endog=dados_fatorial['Y'],
                                   groups=dados_fatorial['Grupo'],
                                   alpha=0.05)
print("\nTeste Post-Hoc de Tukey HSD (Combinacoes):")
print(tukey_fatorial)
```

—

3 Parte III: Análise de Resultados Esperados e Conclusões

3.1 Análise do TCL em Distribuição Assimétrica

A simulação da **Parte I** deverá produzir uma Taxa de Cobertura do IC próxima de 0.95.

1. **Efeito da Assimetria:** A população Exponencial original é fortemente assimétrica (skewness ≈ 2).
2. **Validação do TCL:** A distribuição das médias amostrais para $n = 50$ deve ter sua assimetria próxima de zero, e a forma do histograma deve ser aproximadamente Normal. O TCL garante que, para um n grande o suficiente, a distribuição amostral se torna normal.
3. **Validação do IC:** A taxa de cobertura do 95% IC é mantida (≈ 0.95), comprovando que a Normalidade da distribuição das médias amostrais (via TCL) permite o uso confiável do método do IC baseado na distribuição t ou z, independentemente da distribuição populacional.

3.2 Análise da ANOVA de Planejamento Experimental

3.2.1 Exercício 2: RCBD (Blocagem)

A comparação entre a ANOVA RCBD e CRD ilustrará o **ganho de poder estatístico**.

- **Efeito do Bloco:** O `Bloco` (Gaiola) terá um P-valor muito baixo, indicando que a variação entre as gaiolas é significativa.
- **Erro Residual ($\mathbf{MS_{Residuo}}$):** O valor do $\text{MS}_{\text{Residuo}}$ será significativamente **menor** no modelo RCBD do que no modelo CRD.

- **Tratamento (Dieta):** O P-valor da `Dieta` será **menor no modelo RCBD**, confirmando a rejeição de H_0 de forma mais robusta, pois a variação sistemática do bloco foi isolada do erro aleatório.

3.2.2 Exercício 3: ANOVA Fatorial (Interação)

- **Interação T $\times$ I:** O P-valor para o termo de interação (`Temperatura:Irrigacao`) será **significativamente baixo** ($P \ll 0.05$), indicando que o efeito da Irrigação depende criticamente da Temperatura.
- **Tukey HSD:** A análise do Tukey HSD nas 4 combinações (`T1 x I1`, `T1 x I2`, `T2 x I1`, `T2 x I2`) confirmará o padrão de **inversão**: a Irrigação Máxima (`I2`) é a melhor escolha apenas na Temperatura Baixa (`T1`), sendo uma das piores na Temperatura Alta (`T2`).
- **Conclusão:** A significância da interação **impede a interpretação isolada** dos efeitos principais, exigindo uma recomendação baseada na combinação ótima (`T1 x I2`).